

HeartAI: Sistem Prediksi Risiko Penyakit Jantung Menggunakan Classification, Clustering, dan Explainable AI Berbasis Streamlit

Vania Setyorini Purba, Rozalinda Titalia Putri

Sistem Informasi, Universitas Negeri Surabaya

24051214064@mhs.unesa.ac.id

24051214069@mhs.unesa.ac.id

Abstrak— Proyek UAS ini membahas penerapan Data Mining untuk memprediksi risiko penyakit jantung menggunakan *Heart Disease Dataset* yang diperoleh dari Kaggle. Dataset ini dipilih karena sesuai dengan ketentuan proyek, yaitu memiliki lebih dari 500 data dan lebih dari 5 atribut. Dataset terdiri dari 1.025 baris data dan 14 atribut yang berisi informasi klinis pasien, seperti usia, jenis kelamin, tipe nyeri dada, tekanan darah, kadar kolesterol, gula darah puasa, detak jantung maksimum, angina akibat olahraga, nilai *oldpeak*, dan target penyakit jantung. Penelitian ini menggunakan framework CRISP-DM yang terdiri dari tahapan pemahaman masalah, pemahaman data, persiapan data, pembangunan model, evaluasi model, dan implementasi sistem. Metode Data Mining yang digunakan adalah *classification* dan *clustering*. *Classification* digunakan untuk memprediksi apakah pasien termasuk kategori normal atau berisiko penyakit jantung, sedangkan *clustering* digunakan untuk mengelompokkan pasien berdasarkan kemiripan karakteristik kesehatannya. Pada tahap *classification*, algoritma yang digunakan adalah Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble. Regresi Logistik digunakan sebagai model dasar karena sesuai untuk klasifikasi biner, Random Forest dan Gradient Boosting digunakan sebagai model berbasis pohon keputusan, SVM digunakan sebagai model pembandingan, sedangkan Voting Ensemble digunakan untuk menggabungkan prediksi dari beberapa model. Pada tahap *clustering*, algoritma K-Means digunakan untuk membentuk kelompok pasien berdasarkan kemiripan data klinis. Proses penelitian meliputi pemuatan dataset, pengecekan data, pembersihan data, eksplorasi data, preprocessing, pembagian data latih dan data uji, pembuatan model *classification*, pembuatan model *clustering*, evaluasi model, serta implementasi model ke dalam aplikasi web berbasis Streamlit. Aplikasi yang dibuat bernama HeartAI dan memiliki beberapa halaman, yaitu Beranda, Dataset, Prediksi, XAI Analysis, Dashboard, dan Tentang. Melalui halaman Dataset, pengguna dapat melihat informasi dataset, statistik deskriptif, distribusi data, korelasi antar fitur, dan *feature importance*. Melalui halaman Prediksi, pengguna dapat memasukkan data klinis pasien dan melihat hasil prediksi risiko penyakit jantung beserta probabilitas model. Aplikasi juga dilengkapi fitur Explainable AI menggunakan SHAP dan LIME untuk membantu menjelaskan faktor-faktor yang memengaruhi hasil

prediksi. Selain itu, halaman Dashboard digunakan untuk menampilkan visualisasi performa model dan analisis data secara interaktif. Berdasarkan proyek ini, penerapan Data Mining dapat membantu menganalisis pola pada data kesehatan, membangun model prediksi awal risiko penyakit jantung, dan menyajikan hasil analisis dalam bentuk aplikasi web yang lebih mudah dipahami oleh pengguna. Namun, aplikasi ini hanya digunakan untuk tujuan pembelajaran dan tidak dapat menggantikan diagnosis dari dokter atau tenaga medis profesional.

Kata Kunci— Data Mining, Heart Disease Dataset, Penyakit Jantung, Classification, Clustering, Regresi Logistik, Random Forest, Gradient Boosting, SVM, Voting Ensemble, K-Means, CRISP-DM, Streamlit, SHAP, LIME.

I. PENDAHULUAN

A. LATAR BELAKANG

Kesehatan merupakan salah satu aspek penting dalam kehidupan manusia. Setiap orang membutuhkan kondisi tubuh yang sehat agar dapat menjalankan aktivitas sehari-hari dengan baik. Salah satu penyakit yang perlu mendapatkan perhatian serius adalah penyakit jantung. Penyakit jantung termasuk dalam kelompok penyakit kardiovaskular, yaitu gangguan yang menyerang jantung dan pembuluh darah. Penyakit ini dapat dipengaruhi oleh berbagai faktor, seperti usia, tekanan darah, kadar kolesterol, gula darah, detak jantung, riwayat kesehatan, dan kondisi fisik lainnya. Penyakit jantung perlu diperhatikan karena dapat menimbulkan risiko serius apabila tidak diketahui dan tidak ditangani sejak dini [1].

Seiring dengan perkembangan teknologi, data kesehatan dapat dimanfaatkan untuk membantu proses analisis dan pengambilan keputusan. Data pasien yang berisi informasi klinis dapat dianalisis untuk menemukan pola tertentu yang berhubungan dengan risiko penyakit jantung. Salah satu pendekatan yang dapat digunakan adalah Data Mining. Data Mining merupakan proses untuk menemukan pola, hubungan, atau informasi penting dari sekumpulan data. Dalam bidang kesehatan, Data Mining dapat digunakan untuk membantu menganalisis data pasien, memprediksi kemungkinan suatu

penyakit, serta memberikan informasi pendukung dalam proses pengambilan keputusan [2].

Pada proyek UAS ini, dataset yang digunakan adalah *Heart Disease Dataset* yang diperoleh dari Kaggle. Dataset ini terdiri dari 1.025 baris data dan 14 atribut. Atribut yang tersedia meliputi usia, jenis kelamin, tipe nyeri dada, tekanan darah saat istirahat, kadar kolesterol, gula darah puasa, hasil elektrokardiografi, detak jantung maksimum, angina akibat olahraga, nilai *oldpeak*, kemiringan segmen ST, jumlah pembuluh darah utama, hasil tes thalium, dan target penyakit jantung. Atribut target digunakan untuk menunjukkan apakah pasien termasuk kategori normal atau terindikasi penyakit jantung. Dataset ini dipilih karena sesuai dengan ketentuan proyek, yaitu memiliki lebih dari 500 data dan lebih dari 5 atribut, serta relevan untuk dianalisis menggunakan metode Data Mining [3].

Dalam proyek ini, digunakan dua metode utama Data Mining, yaitu *classification* dan *clustering*. Metode *classification* digunakan untuk membangun model yang dapat memprediksi apakah seorang pasien termasuk kategori normal atau berisiko penyakit jantung berdasarkan data klinis yang dimasukkan. Algoritma *classification* yang digunakan pada aplikasi adalah Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble. Regresi Logistik digunakan sebagai model dasar karena sesuai untuk permasalahan klasifikasi biner dan mudah dipahami. Random Forest dan Gradient Boosting digunakan karena mampu mempelajari pola data yang lebih kompleks melalui pendekatan berbasis pohon keputusan. SVM digunakan sebagai model pembanding, sedangkan Voting Ensemble digunakan untuk menggabungkan beberapa model agar hasil prediksi menjadi lebih stabil. Metode *classification* sesuai digunakan pada proyek ini karena dataset memiliki atribut target yang membagi data ke dalam dua kelas, yaitu pasien normal dan pasien terindikasi penyakit jantung [2].

Selain *classification*, proyek ini juga menggunakan metode *clustering*. *Clustering* digunakan untuk mengelompokkan data pasien berdasarkan kemiripan karakteristik kesehatannya. Dengan *clustering*, data pasien dapat dibagi ke dalam beberapa kelompok yang memiliki pola tertentu. Salah satu algoritma *clustering* yang digunakan adalah K-Means. K-Means bekerja dengan cara membagi data ke dalam beberapa kelompok berdasarkan kedekatan jarak antara data dan pusat cluster. Metode ini digunakan untuk membantu memahami pola kelompok pasien berdasarkan atribut klinis yang tersedia [4].

Proyek ini menggunakan framework CRISP-DM sebagai tahapan kerja Data Mining. CRISP-DM terdiri dari enam tahapan, yaitu *business understanding*, *data understanding*, *data preparation*, *modeling*, *evaluation*, dan *deployment*. Dengan menggunakan framework ini, proses penelitian dapat dilakukan secara lebih terarah, mulai dari memahami permasalahan, memahami dataset, menyiapkan

data, membangun model, mengevaluasi model, hingga mengimplementasikan model ke dalam aplikasi web [5].

Model dan hasil analisis kemudian diimplementasikan ke dalam aplikasi web berbasis Streamlit bernama **HeartAI**. Aplikasi ini dibuat agar pengguna dapat melihat informasi dataset, memahami visualisasi data, memasukkan data klinis pasien, dan melihat hasil prediksi risiko penyakit jantung. Aplikasi HeartAI memiliki beberapa halaman, yaitu **Beranda**, **Dataset**, **Prediksi**, **XAI Analysis**, **Dashboard**, dan **Tentang**. Halaman Dataset digunakan untuk menampilkan informasi dataset, statistik deskriptif, distribusi data, korelasi fitur, dan *feature importance*. Halaman Prediksi digunakan untuk memasukkan data klinis pasien dan menampilkan hasil prediksi beserta probabilitas model. Halaman XAI Analysis digunakan untuk menjelaskan faktor-faktor yang memengaruhi hasil prediksi menggunakan SHAP dan LIME. Halaman Dashboard digunakan untuk menampilkan visualisasi performa model dan analisis data secara interaktif.

Melalui proyek ini, diharapkan dapat diperoleh pemahaman mengenai penerapan Data Mining dalam bidang kesehatan, khususnya untuk membantu prediksi awal risiko penyakit jantung. Proyek ini juga diharapkan dapat menunjukkan bagaimana data klinis pasien dapat diproses, dianalisis, dimodelkan, dievaluasi, dan diimplementasikan ke dalam aplikasi web sederhana. Namun, aplikasi yang dibuat dalam proyek ini hanya digunakan untuk tujuan pembelajaran dan tidak dapat menggantikan diagnosis dari dokter atau tenaga medis profesional.

B. IDENTIFIKASI MASALAH

Berdasarkan latar belakang di atas, dapat diidentifikasi beberapa masalah sebagai berikut:

1. Penyakit jantung merupakan salah satu penyakit yang perlu mendapatkan perhatian serius karena dapat menimbulkan risiko kesehatan yang tinggi apabila tidak diketahui sejak dini.
2. Data kesehatan pasien memiliki berbagai atribut klinis, seperti usia, tekanan darah, kadar kolesterol, detak jantung maksimum, jenis nyeri dada, dan atribut lainnya, sehingga perlu dianalisis untuk mengetahui pola yang berkaitan dengan risiko penyakit jantung.
3. Informasi risiko penyakit jantung tidak dapat diketahui secara langsung hanya dari data mentah, sehingga diperlukan proses Data Mining untuk membantu menemukan pola dan membuat prediksi awal.
4. Diperlukan metode *classification* untuk memprediksi apakah pasien termasuk kategori normal atau berisiko penyakit jantung berdasarkan data klinis yang dimasukkan.

5. Diperlukan beberapa algoritma *classification*, seperti Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble, agar hasil prediksi dapat dibandingkan dan diperoleh model dengan performa yang baik.
6. Diperlukan metode *clustering* untuk mengelompokkan pasien berdasarkan kemiripan karakteristik kesehatannya agar pola kelompok pasien dapat lebih mudah dipahami.
7. Diperlukan aplikasi web berbasis Streamlit yang dapat menampilkan informasi dataset, hasil prediksi, visualisasi data, penjelasan model, dan dashboard secara interaktif.

C. TUJUAN

Pelaksanaan proyek UAS Data Mining ini memiliki beberapa tujuan sebagai berikut:

1. Mengolah *Heart Disease Dataset* yang diperoleh dari Kaggle sebagai dataset utama dalam proyek Data Mining.
2. Melakukan proses pengecekan data, pembersihan data, eksplorasi data, dan *preprocessing* agar dataset siap digunakan untuk analisis dan pemodelan.
3. Membangun model *classification* menggunakan Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble untuk memprediksi risiko penyakit jantung berdasarkan data klinis pasien.
4. Membandingkan performa beberapa model *classification* menggunakan metrik evaluasi seperti *accuracy*, *precision*, *recall*, *F1-score*, dan *ROC-AUC*.
5. Membangun model *clustering* menggunakan K-Means untuk mengelompokkan pasien berdasarkan kemiripan karakteristik kesehatannya.
6. Mengimplementasikan hasil model dan analisis ke dalam aplikasi web berbasis Streamlit bernama **HeartAI**.
7. Menyajikan hasil analisis data, prediksi risiko penyakit jantung, penjelasan model menggunakan SHAP dan LIME, serta dashboard visualisasi dalam bentuk aplikasi yang mudah dipahami oleh pengguna.

D. MANFAAT

Proyek ini diharapkan dapat memberikan beberapa manfaat sebagai berikut:

1. Memberikan pemahaman mengenai penerapan Data Mining dalam bidang kesehatan, khususnya pada analisis risiko penyakit jantung.

2. Membantu memahami bagaimana data klinis pasien dapat digunakan untuk menemukan pola yang berkaitan dengan kondisi kesehatan jantung.
3. Memberikan contoh penerapan metode *classification* menggunakan Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble untuk memprediksi risiko penyakit jantung.
4. Memberikan contoh penerapan metode *clustering* menggunakan K-Means untuk mengelompokkan pasien berdasarkan kemiripan karakteristik kesehatannya.
5. Membantu pengguna memahami hasil prediksi melalui fitur Explainable AI menggunakan SHAP dan LIME.
6. Menunjukkan bagaimana model Data Mining dapat diimplementasikan ke dalam aplikasi web sederhana menggunakan Streamlit.
7. Menyajikan hasil analisis dalam bentuk visualisasi dan dashboard interaktif agar lebih mudah dipahami.

E. BATASAN MASALAH

Agar pembahasan proyek lebih terarah, maka batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Dataset yang digunakan adalah *Heart Disease Dataset* yang diperoleh dari Kaggle dengan 1.025 baris data dan 14 atribut.
2. Penelitian hanya menggunakan atribut yang tersedia dalam dataset, seperti usia, jenis kelamin, tipe nyeri dada, tekanan darah, kadar kolesterol, gula darah puasa, detak jantung maksimum, dan atribut klinis lainnya.
3. Metode Data Mining yang digunakan adalah *classification* dan *clustering*.
4. Algoritma *classification* yang digunakan adalah Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble.
5. Algoritma *clustering* yang digunakan adalah K-Means.
6. Aplikasi web yang dikembangkan menggunakan Streamlit dengan nama **HeartAI** dan berfungsi sebagai media implementasi model, prediksi risiko penyakit jantung, visualisasi data, Explainable AI, serta dashboard analisis.
7. Aplikasi yang dibuat hanya digunakan untuk tujuan pembelajaran dan prediksi awal, sehingga tidak dapat menggantikan diagnosis dokter atau tenaga medis profesional. diagnosis dokter atau tenaga medis profesional.

II. TINJAUAN PUSTAKA

A. Data Mining

Data Mining merupakan proses untuk menemukan pola, hubungan, atau informasi penting dari sekumpulan data. Data yang berukuran besar biasanya sulit dipahami jika hanya dilihat secara langsung, sehingga diperlukan metode tertentu agar data tersebut dapat diolah menjadi informasi yang bermanfaat. Data Mining banyak digunakan dalam berbagai bidang, seperti bisnis, pendidikan, keuangan, transportasi, dan kesehatan [6].

Dalam bidang kesehatan, Data Mining dapat digunakan untuk membantu menganalisis data pasien. Data kesehatan biasanya berisi informasi klinis, seperti usia, tekanan darah, kadar kolesterol, detak jantung, dan riwayat pemeriksaan medis lainnya. Melalui proses Data Mining, data tersebut dapat dianalisis untuk menemukan pola yang berkaitan dengan kondisi kesehatan pasien. Salah satu contoh penerapannya adalah prediksi risiko penyakit jantung berdasarkan data klinis pasien.

Pada proyek ini, Data Mining digunakan untuk mengolah *Heart Disease Dataset*. Dataset tersebut memiliki atribut klinis pasien dan atribut target yang menunjukkan kondisi pasien, yaitu normal atau terindikasi penyakit jantung. Oleh karena itu, Data Mining sesuai digunakan dalam proyek ini karena dapat membantu membangun model prediksi dan menemukan pola kelompok pasien berdasarkan kemiripan karakteristik kesehatannya.

B. CRISP-DM Framework

CRISP-DM atau *Cross Industry Standard Process for Data Mining* merupakan salah satu framework yang sering digunakan dalam proyek Data Mining. Framework ini menyediakan tahapan kerja yang sistematis agar proses pengolahan data dapat dilakukan secara terarah. CRISP-DM terdiri dari enam tahapan utama, yaitu *business understanding*, *data understanding*, *data preparation*, *modeling*, *evaluation*, dan *deployment* [7].

Tahap *business understanding* digunakan untuk memahami masalah yang ingin diselesaikan. Tahap *data understanding* digunakan untuk memahami struktur dan isi dataset. Tahap *data preparation* dilakukan untuk menyiapkan data agar siap digunakan dalam proses pemodelan. Tahap *modeling* digunakan untuk membangun model Data Mining. Tahap *evaluation* digunakan untuk menilai performa model. Tahap terakhir adalah *deployment*, yaitu menerapkan model ke dalam bentuk sistem atau aplikasi.

Pada proyek ini, CRISP-DM digunakan sebagai alur kerja utama. Proses dimulai dari memahami permasalahan

penyakit jantung, memahami dataset, melakukan *preprocessing*, membangun model *classification* dan *clustering*, mengevaluasi model, lalu mengimplementasikan hasil analisis ke dalam aplikasi web berbasis Streamlit bernama **HeartAI**.

C. Classification

Classification merupakan salah satu metode Data Mining yang digunakan untuk memprediksi kelas atau kategori dari suatu data. Metode ini membutuhkan data yang sudah memiliki label atau target. Model akan mempelajari pola dari data latih, kemudian menggunakan pola tersebut untuk memprediksi data baru [6].

Dalam proyek ini, *classification* digunakan untuk memprediksi apakah pasien termasuk kategori normal atau berisiko penyakit jantung. Dataset yang digunakan memiliki atribut target, sehingga cocok untuk diterapkan metode *classification*. Target pada dataset terdiri dari dua kelas, yaitu kelas 0 untuk pasien normal dan kelas 1 untuk pasien terindikasi penyakit jantung.

Algoritma *classification* yang digunakan dalam proyek ini adalah Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble. Beberapa model tersebut digunakan agar hasil prediksi dapat dibandingkan berdasarkan nilai evaluasi seperti *accuracy*, *precision*, *recall*, *F1-score*, dan *ROC-AUC*. Dengan membandingkan beberapa model, dapat diketahui model yang memiliki performa terbaik dalam memprediksi risiko penyakit jantung.

D. Logistic Regression

Logistic Regression atau Regresi Logistik merupakan algoritma machine learning yang sering digunakan untuk menyelesaikan masalah klasifikasi, khususnya klasifikasi biner. Klasifikasi biner adalah proses klasifikasi yang hanya memiliki dua kelas, misalnya “normal” dan “berisiko penyakit jantung”. Regresi Logistik bekerja dengan menghitung peluang suatu data masuk ke dalam kelas tertentu berdasarkan nilai fitur yang dimiliki [8].

Pada proyek ini, Regresi Logistik digunakan karena sesuai dengan karakteristik dataset yang memiliki dua kelas target. Selain itu, Regresi Logistik juga mudah dipahami dan sering digunakan sebagai model dasar dalam permasalahan klasifikasi. Model ini dapat membantu memberikan prediksi awal apakah pasien termasuk kategori normal atau berisiko penyakit jantung berdasarkan atribut klinis yang dimasukkan.

Regresi Logistik juga cocok digunakan dalam proyek pembelajaran karena proses kerjanya relatif sederhana dibandingkan beberapa algoritma lain. Dengan demikian, mahasiswa dapat lebih mudah memahami hubungan antara data input, proses pemodelan, dan hasil prediksi yang diberikan oleh model.

E. Random Forest

Random Forest merupakan algoritma machine learning yang termasuk dalam metode *ensemble learning*. Algoritma ini bekerja dengan membangun banyak pohon keputusan atau *decision tree*, kemudian menggabungkan hasil prediksi dari setiap pohon untuk menentukan hasil akhir. Pada masalah klasifikasi, Random Forest menentukan kelas berdasarkan suara terbanyak dari pohon-pohon keputusan yang dibangun [9].

Random Forest memiliki kelebihan karena dapat menangani banyak fitur dan mampu mempelajari pola data yang kompleks. Algoritma ini juga sering digunakan sebagai model pembandingan dalam berbagai kasus klasifikasi karena performanya cukup baik pada data tabular. Selain itu, Random Forest dapat memberikan informasi mengenai fitur yang dianggap penting dalam proses prediksi atau dikenal dengan istilah *feature importance*.

Dalam proyek ini, Random Forest digunakan sebagai salah satu model utama untuk memprediksi risiko penyakit jantung. Random Forest juga digunakan untuk menampilkan *feature importance* pada aplikasi HeartAI, sehingga pengguna dapat mengetahui atribut mana saja yang dianggap paling berpengaruh terhadap hasil prediksi.

F. Gradient Boosting

Gradient Boosting merupakan algoritma machine learning berbasis pohon keputusan yang bekerja dengan cara membangun model secara bertahap. Model baru dibuat untuk memperbaiki kesalahan dari model sebelumnya. Dengan cara tersebut, Gradient Boosting dapat menghasilkan prediksi yang lebih kuat karena setiap model saling melengkapi dalam memperbaiki kesalahan prediksi [11].

Gradient Boosting banyak digunakan pada data tabular karena mampu mempelajari hubungan yang kompleks antar fitur. Algoritma ini dapat menjadi model pembandingan yang baik terhadap Regresi Logistik dan Random Forest. Pada proses klasifikasi penyakit jantung, Gradient Boosting digunakan untuk memprediksi apakah pasien termasuk kategori normal atau berisiko berdasarkan data klinis yang dimasukkan.

Dalam proyek ini, Gradient Boosting digunakan sebagai salah satu model tambahan pada aplikasi HeartAI. Hasil model ini dibandingkan dengan model lain berdasarkan metrik evaluasi, seperti *accuracy*, *precision*, *recall*, *F1-score*, dan *ROC-AUC*. Dengan adanya Gradient Boosting, analisis model menjadi lebih lengkap karena tidak hanya menggunakan satu atau dua algoritma saja.

G. Support Vector Machine

Support Vector Machine atau SVM merupakan algoritma machine learning yang dapat digunakan untuk masalah klasifikasi. SVM bekerja dengan mencari batas pemisah terbaik antara dua kelas. Batas pemisah tersebut digunakan untuk membedakan data yang termasuk ke dalam kelas normal dan data yang termasuk ke dalam kelas berisiko penyakit jantung [11].

SVM memiliki kelebihan karena dapat digunakan untuk memisahkan data berdasarkan pola tertentu. Pada kasus klasifikasi biner, SVM dapat membantu menentukan apakah data pasien lebih dekat ke kelompok normal atau kelompok terindikasi penyakit jantung. Dalam aplikasi HeartAI, SVM digunakan sebagai model pembandingan terhadap model lain.

Penggunaan SVM pada proyek ini bertujuan untuk memperkaya proses evaluasi model. Dengan membandingkan SVM dengan Regresi Logistik, Random Forest, Gradient Boosting, dan Ensemble, peneliti dapat melihat perbedaan performa antar algoritma dalam melakukan prediksi risiko penyakit jantung.

H. Voting Ensemble

Voting Ensemble merupakan metode yang menggabungkan beberapa model machine learning untuk menghasilkan satu keputusan akhir. Pada metode ini, beberapa model akan memberikan prediksi, kemudian hasil prediksi tersebut digabungkan untuk menentukan hasil akhir. Voting Ensemble dapat digunakan untuk meningkatkan kestabilan prediksi karena tidak hanya bergantung pada satu model saja [11].

Dalam proyek ini, Voting Ensemble digunakan dengan menggabungkan beberapa model, yaitu Regresi Logistik, Random Forest, Gradient Boosting, dan SVM. Penggabungan model tersebut bertujuan agar hasil prediksi menjadi lebih stabil dan dapat mempertimbangkan keputusan dari beberapa algoritma sekaligus.

Pada aplikasi HeartAI, Voting Ensemble digunakan untuk memberikan hasil prediksi utama kepada pengguna. Selain itu, aplikasi juga menampilkan perbandingan hasil prediksi dari beberapa model agar pengguna dapat melihat tingkat kesepakatan antar model. Dengan demikian, pengguna tidak hanya melihat hasil akhir, tetapi juga dapat mengetahui bagaimana beberapa model memberikan prediksi terhadap data pasien yang dimasukkan.

I. Means Clustering

Clustering merupakan metode Data Mining yang digunakan untuk mengelompokkan data berdasarkan kemiripan karakteristik. Berbeda dengan *classification*, metode *clustering* tidak membutuhkan label target. Data akan

dikelompokkan berdasarkan pola atau kedekatan antar data [6].

Salah satu algoritma *clustering* yang sering digunakan adalah K-Means. K-Means bekerja dengan menentukan jumlah kelompok atau *cluster* terlebih dahulu, kemudian data akan dibagi ke dalam *cluster* berdasarkan jarak terdekat dengan pusat *cluster* atau *centroid*. Proses ini dilakukan berulang sampai posisi *cluster* menjadi stabil [10].

Pada proyek ini, K-Means digunakan untuk mengelompokkan pasien berdasarkan kemiripan karakteristik klinis. Dengan menggunakan *clustering*, data pasien dapat dibagi ke dalam beberapa kelompok yang memiliki karakteristik kesehatan yang mirip. Hasil *clustering* digunakan sebagai analisis tambahan untuk memahami pola kelompok pasien dalam dataset.

J. Evaluasi Model

Evaluasi model merupakan tahap penting dalam Data Mining karena digunakan untuk mengetahui seberapa baik model dalam melakukan prediksi atau pengelompokan data. Pada model *classification*, evaluasi dilakukan dengan menggunakan beberapa metrik, seperti *confusion matrix*, *accuracy*, *precision*, *recall*, *F1-score*, dan *ROC-AUC* [11].

Confusion matrix digunakan untuk melihat jumlah prediksi benar dan salah pada masing-masing kelas. *Accuracy* digunakan untuk menghitung persentase prediksi yang benar dari keseluruhan data. *Precision* digunakan untuk melihat seberapa tepat model dalam memprediksi kelas positif. *Recall* digunakan untuk melihat kemampuan model dalam menemukan data positif yang sebenarnya. *F1-score* merupakan nilai gabungan antara *precision* dan *recall*. Sementara itu, *ROC-AUC* digunakan untuk menilai kemampuan model dalam membedakan kelas normal dan kelas berisiko.

Pada model *clustering*, evaluasi dilakukan menggunakan *silhouette score*. Nilai *silhouette score* digunakan untuk melihat seberapa baik data berada dalam *cluster* yang sesuai. Semakin baik pemisahan antar *cluster*, maka hasil *clustering* akan semakin mudah diinterpretasikan. Dalam proyek ini, evaluasi model dilakukan untuk membandingkan performa Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble. Hasil evaluasi digunakan untuk mengetahui model mana yang memiliki performa terbaik dalam memprediksi risiko penyakit jantung.

K. Explainable AI

Explainable AI atau XAI merupakan pendekatan yang digunakan untuk membantu menjelaskan cara kerja dan hasil prediksi model machine learning. Fitur ini penting karena beberapa model machine learning, terutama model

yang kompleks, seringkali sulit dipahami oleh pengguna. Dengan adanya Explainable AI, pengguna dapat mengetahui faktor-faktor apa saja yang memengaruhi hasil prediksi model [11].

Pada proyek ini, Explainable AI digunakan pada aplikasi HeartAI untuk menjelaskan hasil prediksi risiko penyakit jantung. Metode yang digunakan adalah SHAP dan LIME. SHAP digunakan untuk melihat fitur yang paling berpengaruh secara umum terhadap model, sedangkan LIME digunakan untuk menjelaskan prediksi pada satu data pasien tertentu.

Fitur Explainable AI membantu pengguna memahami bahwa hasil prediksi tidak hanya muncul secara otomatis, tetapi dipengaruhi oleh atribut klinis tertentu. Misalnya, atribut seperti jumlah pembuluh darah utama, hasil tes thalium, tipe nyeri dada, nilai *oldpeak*, dan detak jantung maksimum dapat memberikan pengaruh terhadap hasil prediksi model. Dengan demikian, aplikasi tidak hanya menampilkan hasil prediksi, tetapi juga memberikan penjelasan yang lebih mudah dipahami.

L. Streamlit Framework

Streamlit merupakan framework berbasis Python yang digunakan untuk membuat aplikasi web interaktif, khususnya untuk kebutuhan data science dan machine learning. Dengan Streamlit, hasil analisis data dan model machine learning dapat ditampilkan dalam bentuk aplikasi web yang lebih mudah digunakan oleh pengguna [12].

Streamlit memiliki kelebihan karena sintaksnya sederhana dan dapat langsung digunakan bersama library Python seperti Pandas, Scikit-learn, Matplotlib, Plotly, SHAP, LIME, dan Joblib. Oleh karena itu, Streamlit cocok digunakan untuk membuat aplikasi sederhana yang menampilkan informasi dataset, visualisasi data, form input pengguna, hasil prediksi model, penjelasan model, dan dashboard interaktif.

Pada proyek ini, Streamlit digunakan untuk membangun aplikasi web bernama HeartAI. Aplikasi ini memiliki beberapa halaman, yaitu Beranda, Dataset, Prediksi, XAI Analysis, Dashboard, dan Tentang. Melalui aplikasi tersebut, pengguna dapat melihat informasi dataset, melakukan eksplorasi data, memasukkan data klinis pasien, melihat hasil prediksi risiko penyakit jantung, memahami faktor yang memengaruhi prediksi, dan melihat dashboard performa model.

M. Dashboard Interaktif

Dashboard interaktif merupakan tampilan yang digunakan untuk menyajikan informasi dalam bentuk grafik, tabel, dan visualisasi yang mudah dipahami. Dashboard membantu pengguna memahami hasil analisis tanpa harus membaca seluruh kode program atau membuka notebook

analisis. Dalam proyek Data Mining, dashboard dapat digunakan untuk menampilkan informasi dataset, performa model, distribusi data, dan pola hubungan antar fitur [12].

Pada proyek ini, dashboard digunakan sebagai salah satu halaman dalam aplikasi HeartAI. Dashboard menampilkan performa model, seperti hasil *cross-validation*, akurasi data uji, dan tabel ringkasan evaluasi model. Selain itu, dashboard juga menampilkan analisis data seperti risiko berdasarkan kelompok usia dan hubungan antara kadar kolesterol dengan detak jantung maksimum. Dengan adanya dashboard, hasil analisis menjadi lebih mudah dipahami oleh pengguna. Dashboard juga membuat aplikasi lebih interaktif karena pengguna dapat melihat informasi penting secara visual, bukan hanya dalam bentuk angka atau teks.

N. Penelitian Terkait

Beberapa penelitian sebelumnya telah membahas penerapan machine learning dan Data Mining dalam bidang kesehatan, khususnya untuk prediksi penyakit jantung. Penelitian-penelitian tersebut menunjukkan bahwa data klinis pasien dapat digunakan sebagai dasar untuk membangun model prediksi penyakit.

Penelitian oleh Detrano et al. membahas penggunaan data klinis untuk membantu diagnosis penyakit jantung. Penelitian tersebut menjadi salah satu dasar dari penggunaan dataset penyakit jantung yang banyak digunakan dalam penelitian machine learning hingga saat ini [13].

Penelitian oleh Mohan et al. membahas prediksi penyakit jantung menggunakan teknik machine learning. Penelitian tersebut menjelaskan bahwa algoritma machine learning dapat digunakan untuk membantu menganalisis faktor-faktor yang berkaitan dengan penyakit jantung berdasarkan atribut klinis pasien [14].

Penelitian oleh Uyar dan İlhan juga membahas diagnosis penyakit jantung menggunakan pendekatan machine learning. Penelitian tersebut menunjukkan bahwa metode komputasi dapat digunakan sebagai alat bantu analisis dalam bidang kesehatan, terutama untuk membantu proses prediksi berdasarkan data medis [15].

III. METODOLOGI

A. Framework CRISP-DM


Metodologi yang digunakan dalam proyek ini adalah CRISP-DM atau *Cross Industry Standard Process for Data Mining*. CRISP-DM dipilih karena memiliki tahapan kerja yang jelas dan sistematis dalam menyelesaikan proyek Data Mining. Dengan menggunakan framework ini, proses

penelitian dapat dilakukan secara lebih terarah, mulai dari memahami masalah, memahami data, menyiapkan data, membangun model, mengevaluasi model, hingga mengimplementasikan hasil model ke dalam aplikasi.

CRISP-DM terdiri dari enam tahapan utama, yaitu *business understanding*, *data understanding*, *data preparation*, *modeling*, *evaluation*, dan *deployment*. Pada proyek ini, seluruh tahapan tersebut diterapkan untuk membangun sistem prediksi risiko penyakit jantung menggunakan *Heart Disease Dataset*. Model yang dibangun kemudian diterapkan ke dalam aplikasi web berbasis Streamlit bernama **HeartAI**.

Tahapan CRISP-DM dalam proyek ini adalah sebagai berikut:

1. *Business Understanding*, yaitu memahami permasalahan yang ingin diselesaikan.
2. *Data Understanding*, yaitu memahami isi, struktur, dan karakteristik dataset.
3. *Data Preparation*, yaitu menyiapkan data agar dapat digunakan dalam pemodelan.
4. *Modeling*, yaitu membangun model *classification* dan *clustering*.
5. *Evaluation*, yaitu mengevaluasi performa model yang telah dibuat.
6. *Deployment*, yaitu mengimplementasikan hasil model ke dalam aplikasi web berbasis Streamlit.



Gbr. 3.1 Diagram Alur CRISP-DM

Gambar 3.1 menunjukkan tahapan CRISP-DM yang digunakan dalam proyek ini. Setiap tahapan dilakukan secara berurutan agar proses Data Mining dapat berjalan dengan

jasas, mulai dari memahami masalah hingga implementasi sistem.

B. Business Understanding

Tahap *business understanding* merupakan tahap awal dalam CRISP-DM. Pada tahap ini dilakukan pemahaman terhadap permasalahan yang ingin diselesaikan. Permasalahan utama dalam proyek ini adalah bagaimana memanfaatkan data klinis pasien untuk membantu melakukan prediksi awal terhadap risiko penyakit jantung.

Penyakit jantung merupakan salah satu penyakit yang perlu diperhatikan karena dapat menimbulkan risiko serius apabila tidak diketahui sejak dini. Dalam bidang kesehatan, data pasien dapat digunakan sebagai sumber informasi untuk membantu proses analisis. Data yang berisi atribut klinis pasien dapat diolah menggunakan metode Data Mining untuk menemukan pola tertentu yang berkaitan dengan risiko penyakit jantung.

Tujuan dari tahap ini adalah menentukan arah penelitian agar proses analisis tidak hanya berfokus pada pengolahan data, tetapi juga memiliki manfaat yang jelas. Dalam proyek ini, tujuan utamanya adalah membangun model Data Mining yang dapat digunakan untuk memprediksi apakah pasien termasuk kategori normal atau berisiko penyakit jantung. Selain itu, proyek ini juga bertujuan untuk mengelompokkan pasien berdasarkan kemiripan karakteristik kesehatannya.

Berdasarkan tujuan tersebut, metode Data Mining yang digunakan adalah *classification* dan *clustering*. *Classification* digunakan untuk memprediksi status risiko penyakit jantung, sedangkan *clustering* digunakan untuk mengelompokkan pasien berdasarkan kemiripan data klinis. Hasil dari model kemudian diimplementasikan ke dalam aplikasi web berbasis Streamlit agar dapat digunakan secara lebih interaktif oleh pengguna.

C. Data Understanding

Tahap *data understanding* dilakukan untuk memahami dataset yang digunakan dalam proyek. Dataset yang digunakan adalah *Heart Disease Dataset* yang diperoleh dari Kaggle. Dataset ini memiliki 1.025 baris data dan 14 atribut. Setiap baris data merepresentasikan data seorang pasien, sedangkan setiap kolom merepresentasikan atribut klinis yang berkaitan dengan kondisi kesehatan pasien.


Atribut yang terdapat dalam dataset adalah sebagai berikut:

1. age, yaitu usia pasien.
2. sex, yaitu jenis kelamin pasien.
3. cp, yaitu tipe nyeri dada atau *chest pain type*.
4. trestbps, yaitu tekanan darah saat istirahat.

5. chol, yaitu kadar kolesterol pasien.
6. fbs, yaitu kadar gula darah puasa.
7. restecg, yaitu hasil elektrokardiografi saat istirahat.
8. thalach, yaitu detak jantung maksimum yang dicapai.
9. exang, yaitu kondisi angina akibat olahraga.
10. oldpeak, yaitu penurunan segmen ST akibat olahraga dibandingkan saat istirahat.
11. slope, yaitu kemiringan segmen ST.
12. ca, yaitu jumlah pembuluh darah utama yang terdeteksi.
13. thal, yaitu hasil tes thalium.
14. target, yaitu status penyakit jantung.

Atribut target digunakan sebagai label dalam proses *classification*. Nilai target menunjukkan apakah pasien termasuk kategori normal atau terindikasi penyakit jantung. Dalam proyek ini, target digunakan untuk melatih model agar dapat memprediksi risiko penyakit jantung berdasarkan atribut klinis lainnya.

Pada tahap ini juga dilakukan pemeriksaan awal terhadap dataset, seperti melihat jumlah baris dan kolom, tipe data, nilai kosong, data duplikat, dan statistik deskriptif. Berdasarkan hasil pemeriksaan, dataset memiliki 1.025 data, 14 atribut, tidak memiliki nilai kosong, dan memiliki data duplikat. Pemeriksaan ini penting dilakukan untuk mengetahui kondisi data sebelum masuk ke tahap *preproc*



Gbr. 3.2 Alur Pemahaman Dataset

Gambar 3.2 menunjukkan alur pemahaman dataset. Proses dimulai dari memuat dataset, melihat struktur data, mengecek atribut, mengecek nilai kosong, mengecek data duplikat, dan memahami statistik deskriptif dari dataset.

D. Data Preparation

Tahap *data preparation* merupakan tahap untuk menyiapkan data agar dapat digunakan dalam proses


pemodelan. Tahap ini penting karena kualitas data sangat memengaruhi kualitas model yang dihasilkan. Data yang masih mentah perlu diperiksa dan diproses terlebih dahulu agar sesuai dengan kebutuhan algoritma machine learning.

Langkah pertama yang dilakukan adalah memuat dataset ke dalam notebook menggunakan library Pandas. Setelah dataset berhasil dimuat, dilakukan pengecekan struktur data untuk memastikan jumlah baris, jumlah kolom, nama atribut, dan tipe data. Selanjutnya dilakukan pengecekan nilai kosong untuk mengetahui apakah terdapat data yang tidak lengkap. Pada dataset ini, tidak ditemukan nilai kosong.

Langkah berikutnya adalah memeriksa data duplikat. Pemeriksaan data duplikat dilakukan karena data yang berulang dapat memengaruhi proses pelatihan dan evaluasi model. Setelah itu, dilakukan pemisahan antara fitur dan target. Fitur merupakan atribut yang digunakan sebagai input model, sedangkan target merupakan label yang akan diprediksi.

Pada proses *classification*, fitur yang digunakan adalah seluruh atribut selain target, sedangkan target digunakan sebagai label. Data kemudian dibagi menjadi data latih dan data uji. Data latih digunakan untuk melatih model, sedangkan data uji digunakan untuk menguji performa model. Pembagian data ini dilakukan agar model dapat dievaluasi menggunakan data yang belum pernah digunakan dalam proses pelatihan.

Selain itu, dilakukan proses standarisasi menggunakan StandardScaler. Standarisasi dilakukan agar setiap fitur memiliki skala yang seimbang. Proses ini penting terutama untuk algoritma Regresi Logistik, SVM, dan K-Means karena algoritma tersebut cukup sensitif terhadap perbedaan skala data. Dengan standarisasi, fitur seperti tekanan darah, kolesterol, dan detak jantung berada pada skala yang lebih seimbang sehingga proses pemodelan dapat berjalan lebih baik




Gbr.3.3 Alur Data Preparation

E. Modelling Classification

Tahap *modeling* merupakan tahap membangun model Data Mining. Pada bagian *classification*, tujuan model adalah memprediksi apakah pasien termasuk kategori normal atau berisiko penyakit jantung. Karena target pada dataset terdiri dari dua kelas, maka permasalahan ini termasuk ke dalam klasifikasi biner. Algoritma yang digunakan untuk *classification* adalah Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble. Beberapa algoritma tersebut digunakan agar hasil prediksi dapat dibandingkan, sehingga dapat diketahui model mana yang memiliki performa paling baik dalam memprediksi risiko penyakit jantung.

Regresi Logistik digunakan karena algoritma ini sesuai untuk permasalahan klasifikasi biner dan mudah dipahami. Algoritma ini bekerja dengan menghitung peluang suatu data masuk ke kelas tertentu. Dalam proyek ini, Regresi Logistik digunakan untuk memprediksi kemungkinan pasien termasuk kategori normal atau berisiko penyakit jantung berdasarkan atribut klinis yang dimasukkan. Random Forest digunakan karena mampu mempelajari pola data yang lebih kompleks melalui gabungan banyak pohon keputusan. Algoritma ini bekerja dengan membangun beberapa *decision tree*, kemudian hasil prediksi dari setiap pohon digabungkan untuk menentukan hasil akhir. Random Forest juga dapat digunakan untuk melihat fitur yang paling berpengaruh melalui *feature importance*.

Gradient Boosting digunakan sebagai model tambahan berbasis pohon keputusan. Algoritma ini bekerja secara bertahap dengan memperbaiki kesalahan dari model sebelumnya. Dengan cara tersebut, Gradient Boosting dapat menghasilkan prediksi yang cukup kuat dan menjadi pembanding terhadap model lainnya. SVM digunakan sebagai model pembanding lain dalam proses klasifikasi. SVM bekerja dengan mencari batas pemisah terbaik antara dua kelas. Dalam proyek ini, SVM digunakan untuk membedakan pasien normal dan pasien berisiko berdasarkan pola dari atribut klinis yang tersedia. Voting Ensemble digunakan untuk menggabungkan beberapa model, yaitu Regresi Logistik, Random Forest, Gradient Boosting, dan SVM. Tujuannya adalah agar hasil prediksi menjadi lebih stabil karena tidak hanya bergantung pada satu model saja. Pada aplikasi HeartAI, model Ensemble digunakan untuk menampilkan hasil prediksi utama kepada pengguna.



Gbr. 3.4 Alur Modeling Classification


Gambar 3.4 menunjukkan alur pembuatan model *classification*. Proses dimulai dari data yang telah dipreprocessing, kemudian dilakukan pelatihan beberapa model, yaitu Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble. Setelah itu, hasil prediksi dari setiap model dievaluasi untuk mengetahui performanya.

F. Modelling Clustering

Selain *classification*, proyek ini juga menggunakan metode *clustering*. Tujuan dari *clustering* adalah mengelompokkan pasien berdasarkan kemiripan karakteristik kesehatannya. Berbeda dengan *classification*, *clustering* tidak menggunakan atribut target dalam proses pembentukan kelompok. Algoritma *clustering* yang digunakan adalah K-Means. K-Means bekerja dengan membagi data ke dalam sejumlah *cluster* berdasarkan kedekatan jarak antara data dan pusat *cluster*. Pada proyek ini, K-Means digunakan untuk membentuk kelompok pasien berdasarkan atribut klinis yang tersedia dalam dataset.

Sebelum dilakukan *clustering*, atribut target tidak digunakan karena *clustering* bertujuan untuk menemukan kelompok berdasarkan fitur, bukan berdasarkan label. Fitur yang digunakan terlebih dahulu distandardisasi agar setiap atribut memiliki skala yang seimbang. Hal ini penting karena K-Means menggunakan jarak dalam proses pembentukan *cluster*. Jika fitur memiliki skala yang berbeda terlalu jauh, maka fitur dengan nilai besar dapat lebih mendominasi proses *clustering*. Jumlah *cluster* dievaluasi menggunakan *silhouette score*. Nilai ini digunakan untuk melihat seberapa baik data berada dalam *cluster* yang sesuai. Hasil *clustering* digunakan sebagai analisis tambahan untuk memahami karakteristik kelompok pasien.

Gambar 3.5 menunjukkan alur pembuatan model *clustering*. Proses dimulai dari pemilihan fitur tanpa atribut target, standardisasi data, penerapan algoritma K-Means, penentuan cluster, dan evaluasi menggunakan *silhouette score*.




Gbr. 3.5 Alur Modeling Clustering

G. Evaluation

Tahap *evaluation* dilakukan untuk menilai performa model yang telah dibangun. Evaluasi penting dilakukan agar model yang digunakan tidak hanya dapat berjalan, tetapi juga memiliki hasil yang dapat dipertanggungjawabkan. Pada model *classification*, evaluasi dilakukan menggunakan beberapa metrik, yaitu *confusion matrix*, *accuracy*, *precision*, *recall*, *F1-score*, dan *ROC-AUC*. *Confusion matrix* digunakan untuk melihat jumlah prediksi benar dan salah. *Accuracy* digunakan untuk mengetahui persentase prediksi yang benar dari seluruh data uji. *Precision* digunakan untuk mengetahui seberapa tepat model dalam memprediksi pasien berisiko. *Recall* digunakan untuk mengetahui kemampuan model dalam menemukan pasien yang benar-benar berisiko. *F1-score* digunakan sebagai ukuran gabungan antara *precision* dan *recall*. Sementara itu, *ROC-AUC* digunakan untuk melihat kemampuan model dalam membedakan kelas normal dan kelas berisiko.

Model yang dievaluasi pada tahap ini adalah Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble. Evaluasi dilakukan agar dapat diketahui model mana yang memberikan performa terbaik. Pada aplikasi HeartAI, hasil evaluasi juga ditampilkan dalam bentuk grafik dan tabel agar lebih mudah dipahami. Pada model *clustering*, evaluasi dilakukan menggunakan *silhouette score*. Metrik ini digunakan untuk melihat seberapa baik data berada dalam *cluster* yang sesuai. Nilai *silhouette score* dapat membantu menilai apakah hasil pengelompokan sudah cukup baik atau masih perlu diperbaiki.



Gbr. 3.6 Alur Evaluasi Model

Gambar 3.6 menunjukkan alur evaluasi model. Pada model *classification*, evaluasi dilakukan menggunakan *accuracy*, *precision*, *recall*, *F1-score*, *ROC-AUC*, dan *confusion matrix*. Pada model *clustering*, evaluasi dilakukan menggunakan *silhouette score*.

H. Deployment


Tahap *deployment* merupakan tahap implementasi model ke dalam bentuk aplikasi. Pada proyek ini, model *classification*, model *clustering*, hasil visualisasi, dan penjelasan model diimplementasikan ke dalam aplikasi web berbasis Streamlit. Aplikasi yang dibuat diberi nama **HeartAI**.

Aplikasi HeartAI dibuat agar hasil analisis Data Mining dapat digunakan dengan lebih mudah oleh pengguna. Pengguna tidak perlu menjalankan notebook secara langsung, tetapi cukup membuka aplikasi web dan memasukkan data klinis pasien melalui form input yang tersedia. Setelah data dimasukkan, aplikasi akan memproses data tersebut menggunakan model yang telah disiapkan dan menampilkan hasil prediksi.

Aplikasi HeartAI memiliki beberapa halaman, yaitu:

1. Beranda, berisi judul proyek, deskripsi singkat, identitas anggota kelompok, fitur utama aplikasi, dan tahapan CRISP-DM.
2. Dataset, berisi informasi dataset, jumlah data, statistik deskriptif, eksplorasi data, distribusi target, korelasi, dan *feature importance*.
3. Prediksi, berisi form input data pasien, hasil prediksi risiko penyakit jantung, probabilitas model, perbandingan hasil model, *confusion matrix*, dan kurva ROC.
4. XAI Analysis, berisi penjelasan model menggunakan SHAP dan LIME untuk mengetahui fitur yang memengaruhi hasil prediksi.
5. Dashboard, berisi grafik performa model, hasil evaluasi, dan analisis data secara interaktif.
6. Tentang, berisi penjelasan proyek, anggota kelompok, teknologi yang digunakan, informasi dataset, dan disclaimer.

Model yang digunakan dalam aplikasi diproses menggunakan library machine learning di Python. Selain itu, aplikasi juga menggunakan visualisasi interaktif untuk membantu pengguna memahami hasil analisis. Dengan adanya aplikasi HeartAI, hasil proyek tidak hanya berupa model pada notebook, tetapi juga berupa sistem sederhana yang dapat digunakan sebagai media pembelajaran.




Gbr. 3.7 Arsitektur Sederhana Aplikasi

Gambar 3.7 menunjukkan arsitektur sederhana aplikasi HeartAI. Pengguna memasukkan data melalui aplikasi Streamlit, kemudian aplikasi memproses data menggunakan model machine learning. Hasil analisis ditampilkan dalam bentuk prediksi, probabilitas, visualisasi, dashboard, dan penjelasan model.

I. Alur Penelitian

Secara umum, alur penelitian dalam proyek ini dapat dijelaskan sebagai berikut:

1. Menentukan permasalahan, yaitu prediksi awal risiko penyakit jantung.
2. Mengumpulkan dataset dari Kaggle, yaitu *Heart Disease Dataset*.
3. Memahami struktur dataset, jumlah data, atribut, target, dan tipe data.
4. Melakukan pengecekan data kosong, data duplikat, dan statistik deskriptif.
5. Melakukan *preprocessing* data, termasuk pemisahan fitur dan target serta standardisasi.
6. Membagi data menjadi data latih dan data uji.
7. Membangun model *classification* menggunakan Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble.
8. Membangun model *clustering* menggunakan K-Means.
9. Mengevaluasi model *classification* menggunakan *confusion matrix*, *accuracy*, *precision*, *recall*, *F1-score*, dan *ROC-AUC*.
10. Mengevaluasi model *clustering* menggunakan *silhouette score*.
11. Menampilkan hasil analisis dan model ke dalam aplikasi web berbasis Streamlit.
12. Menambahkan fitur XAI Analysis menggunakan SHAP dan LIME.
13. Menambahkan dashboard untuk menampilkan performa model dan analisis data.
14. Melakukan pengujian aplikasi untuk memastikan setiap fitur berjalan sesuai kebutuhan.



Gbr. 8

Gambar 3.8 menunjukkan alur penelitian secara keseluruhan. Proses dimulai dari penentuan masalah, pengumpulan dataset, pemahaman data, persiapan data, pemodelan, evaluasi, implementasi aplikasi, hingga pengujian sistem.


IV. HASIL DAN PEMBAHASAN

A. Hasil Data Understanding

Pada tahap *data understanding*, dilakukan proses pemahaman terhadap dataset yang digunakan dalam penelitian. Dataset yang digunakan adalah *Heart Disease Dataset* yang diperoleh dari Kaggle. Dataset ini berisi data klinis pasien yang digunakan untuk menganalisis dan memprediksi risiko penyakit jantung. Berdasarkan hasil pembacaan dataset, diketahui bahwa dataset memiliki 1.025 baris data dan 14 atribut. Dari 14 atribut tersebut, terdapat 13 atribut yang digunakan sebagai fitur input dan 1 atribut sebagai target. Atribut target digunakan untuk menunjukkan kondisi pasien, yaitu apakah pasien termasuk kategori normal atau terindikasi penyakit jantung.


Atribut yang digunakan sebagai fitur input terdiri dari age, sex, cp, trestbps, chol, fbs, restecg, thalach, exang, oldpeak, slope, ca, dan thal. Sementara itu, atribut target digunakan sebagai label dalam proses klasifikasi. Nilai target 0 menunjukkan pasien normal, sedangkan nilai target 1 menunjukkan pasien terindikasi penyakit jantung. Hasil pengecekan data menunjukkan bahwa dataset tidak memiliki nilai kosong atau *missing value*. Hal ini menunjukkan bahwa seluruh data pada setiap atribut telah terisi, sehingga tidak diperlukan proses pengisian nilai kosong. Namun, pada dataset ditemukan sebanyak 723 data duplikat. Keberadaan data duplikat perlu diperhatikan karena dapat memengaruhi hasil evaluasi model, terutama jika data yang sama muncul pada data latih dan data uji.

Distribusi target pada dataset menunjukkan bahwa data memiliki dua kelas, yaitu kelas normal dan kelas terindikasi penyakit jantung. Jumlah data pada kelas normal adalah 499 data, sedangkan jumlah data pada kelas terindikasi penyakit jantung adalah 526 data. Perbandingan ini menunjukkan bahwa dataset cukup seimbang karena jumlah data pada kedua kelas tidak berbeda terlalu jauh.



Gbr. 4.1 Distribusi Target Penyakit Jantung

Gambar 4.1 menunjukkan distribusi jumlah data pada masing-masing kelas target. Berdasarkan gambar tersebut, dapat dilihat bahwa jumlah pasien normal dan pasien terindikasi penyakit jantung cukup seimbang. Kondisi ini baik untuk proses klasifikasi karena model tidak terlalu berat ke salah satu kelas saja. Selain distribusi target, dilakukan juga analisis terhadap atribut usia. Usia merupakan salah satu atribut penting karena penyakit jantung sering dikaitkan dengan kondisi fisik dan kesehatan seseorang. Melalui visualisasi distribusi usia, dapat diketahui bagaimana penyebaran usia pasien pada masing-masing kelas target.



Gbr. 4.2 Distribusi Usia Berdasarkan Target

Gambar 4.2 menunjukkan distribusi usia pasien berdasarkan target penyakit jantung. Dari visualisasi tersebut, terlihat bahwa pasien pada dataset memiliki rentang usia yang cukup beragam. Analisis distribusi usia ini penting untuk melihat apakah terdapat perbedaan pola usia antara pasien normal dan pasien terindikasi penyakit jantung.

B. Hasil Preprocessing


Tahap preprocessing dilakukan untuk menyiapkan data agar dapat digunakan dalam proses pemodelan. Preprocessing penting dilakukan karena kualitas data sangat berpengaruh terhadap kualitas model yang dihasilkan. Langkah pertama dalam preprocessing adalah melakukan pengecekan nilai kosong. Berdasarkan hasil pengecekan, dataset tidak memiliki nilai kosong, sehingga tidak diperlukan proses imputasi data. Selanjutnya dilakukan pengecekan data duplikat. Hasil pengecekan menunjukkan bahwa terdapat 723 data duplikat. Data duplikat ini menjadi catatan penting dalam proses analisis karena dapat membuat performa model terlihat sangat tinggi.

Setelah pengecekan data, dilakukan pemisahan antara fitur dan target. Fitur digunakan sebagai input model, sedangkan target digunakan sebagai label yang akan diprediksi. Atribut yang digunakan sebagai fitur adalah seluruh kolom selain target, sedangkan kolom target digunakan sebagai label klasifikasi. Data kemudian dibagi menjadi data latih dan data uji menggunakan metode *train-test split*. Data latih digunakan untuk melatih model, sedangkan data uji digunakan untuk menguji performa model. Pada proyek ini, data dibagi dengan komposisi 80% data latih dan 20% data uji.

Selanjutnya dilakukan proses standardisasi menggunakan *StandardScaler*. Standardisasi dilakukan agar setiap fitur memiliki skala yang lebih seimbang. Proses ini penting karena beberapa algoritma, seperti Logistic Regression, SVM, dan K-Means, sensitif terhadap perbedaan skala data. Contohnya, atribut kolesterol dan tekanan darah memiliki rentang nilai yang lebih besar dibandingkan atribut jenis kelamin atau gula darah puasa. Jika tidak distandardisasi, atribut dengan nilai besar dapat lebih mendominasi proses pemodelan.

C. Hasil Analisis Korelasi

Analisis korelasi dilakukan untuk melihat hubungan antar atribut dalam dataset. Korelasi dapat membantu mengetahui atribut mana yang memiliki hubungan cukup kuat dengan atribut lainnya, termasuk dengan target penyakit jantung.




Gbr. 4.3 Matriks Korelasi Antar Atribut

Gambar 4.3 menunjukkan matriks korelasi antar atribut. Melalui visualisasi ini, dapat dilihat hubungan positif maupun negatif antar fitur. Korelasi positif menunjukkan bahwa ketika nilai suatu atribut meningkat, atribut lain cenderung ikut meningkat. Sebaliknya, korelasi negatif menunjukkan bahwa ketika nilai suatu atribut meningkat, atribut lain cenderung menurun. Dalam konteks penyakit jantung, analisis korelasi dapat membantu memahami hubungan antara atribut klinis dengan target penyakit jantung. Namun, korelasi tidak selalu menunjukkan hubungan sebab-akibat. Oleh karena itu, hasil korelasi digunakan sebagai pendukung analisis, bukan sebagai satu-satunya dasar pengambilan kesimpulan.

D. Hasil Feature Importance

Feature importance digunakan untuk mengetahui fitur mana yang memiliki pengaruh besar dalam proses prediksi model. Pada proyek ini, feature importance diperoleh menggunakan algoritma Random Forest. Random Forest dapat memberikan nilai kepentingan fitur berdasarkan kontribusi fitur tersebut dalam membentuk keputusan pada pohon-pohon keputusan.



Gbr. 4.4 Feature Importance Random Forest

Berdasarkan Gambar 4.4, beberapa fitur memiliki pengaruh lebih besar dibandingkan fitur lainnya dalam proses prediksi. Fitur yang memiliki nilai kepentingan tinggi berarti lebih sering digunakan oleh model untuk membedakan pasien normal dan pasien terindikasi penyakit jantung. Analisis ini berguna untuk memahami faktor-faktor yang dianggap penting oleh model. Meskipun demikian, feature importance bukan berarti fitur tersebut secara medis pasti menjadi penyebab penyakit jantung. Feature importance hanya menunjukkan bahwa fitur tersebut memiliki kontribusi besar dalam pola data.

yang dipelajari oleh model. Oleh karena itu, interpretasi hasil tetap harus dilakukan secara hati-hati.

E. Hasil Klasifikasi

Pada tahap klasifikasi, model digunakan untuk memprediksi apakah pasien termasuk kategori normal atau berisiko penyakit jantung. Berdasarkan kode aplikasi yang digunakan, model klasifikasi yang dibangun terdiri dari Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble. Model ensemble digunakan untuk menggabungkan hasil prediksi dari beberapa model agar hasil prediksi menjadi lebih kuat.

Hasil evaluasi model klasifikasi dapat dilihat pada tabel berikut.


Model	Accuracy	Precision	Recall	F1-score	ROC-AUC	CV Mean
Regresi Logistik	0.7951	0.7563	0.8737	0.8108	0.8787	0.84878
Random Forest	0.985	1.0	0.9708	0.9852	1.0	0.9817
Gradient Boosting	0.9317	0.9158	0.9514	0.9333	0.9806	0.95609
SVM	0.8878	0.8508	0.9417	0.8940	0.9631	0.9195

Ensemble	0.9365	0.9017	0.9805	0.9395	0.9907	0.94390
----------	--------	--------	--------	--------	--------	---------

Tabel 4.1 Hasil Evaluasi Model Klasifikasi

Berdasarkan tabel tersebut, Random Forest memperoleh nilai akurasi tertinggi, yaitu 0.9854. Nilai ini menunjukkan bahwa Random Forest mampu melakukan prediksi dengan sangat baik pada data uji. Namun, hasil yang sangat tinggi perlu dianalisis secara hati-hati karena dataset memiliki jumlah data duplikat yang cukup besar. Data duplikat dapat menyebabkan data yang mirip atau sama muncul pada data latih dan data uji, sehingga model menjadi lebih mudah mengenali pola data.

Model Regresi Logistik memperoleh akurasi 0.7951. Meskipun nilainya lebih rendah dibandingkan Random Forest, model ini lebih sederhana dan lebih mudah dipahami. Regresi Logistik cocok digunakan sebagai model dasar dalam klasifikasi biner karena hasilnya lebih mudah dijelaskan. Gradient Boosting memperoleh akurasi 0.9317, sedangkan SVM memperoleh akurasi 0.8878. Kedua model ini menunjukkan performa yang baik dan dapat digunakan sebagai pembanding. Sementara itu, model Ensemble memperoleh akurasi 0.9366 dan nilai ROC-AUC 0.9908. Hal ini menunjukkan bahwa ensemble mampu menggabungkan kekuatan beberapa model sehingga menghasilkan prediksi yang stabil.




Gbr. 4.5 Perbandingan Performa Model Klasifikasi

Gambar 4.5 menunjukkan perbandingan performa beberapa model berdasarkan metrik Accuracy, F1-score, dan ROC-AUC. Dari gambar tersebut, dapat dilihat bahwa Random Forest dan Ensemble memiliki performa yang tinggi dibandingkan model lainnya. Namun, interpretasi performa

tetap perlu mempertimbangkan kondisi data duplikat pada dataset.

F. Hasil Confusion Matrix

Confusion matrix digunakan untuk melihat jumlah prediksi benar dan salah pada masing-masing kelas. Pada proyek ini, confusion matrix digunakan untuk mengevaluasi model Ensemble.




Gbr. 4.6 Confusion Matrix Model Ensemble

Berdasarkan Gambar 4.6, model Ensemble mampu memprediksi sebagian besar data uji dengan benar. Confusion matrix membantu melihat apakah model lebih sering salah memprediksi pasien normal sebagai berisiko atau sebaliknya. Dalam kasus kesehatan, kesalahan memprediksi pasien berisiko sebagai normal perlu diperhatikan karena dapat berpengaruh terhadap interpretasi hasil. Oleh karena itu, selain akurasi, metrik seperti recall dan F1-score juga penting untuk diperhatikan. Recall menunjukkan kemampuan model dalam menemukan pasien yang benar-benar berisiko. Pada model Ensemble, nilai recall sebesar 0.9806, yang menunjukkan bahwa model cukup baik dalam mengenali data pasien berisiko pada data uji.

G. Hasil ROC-AUC

ROC-AUC digunakan untuk melihat kemampuan model dalam membedakan kelas normal dan kelas berisiko penyakit jantung. Semakin tinggi nilai ROC-AUC, semakin baik kemampuan model dalam memisahkan kedua kelas.




Gbr. 4.7 Kurva ROC Model Ensemble

Berdasarkan hasil evaluasi, model Ensemble memperoleh nilai ROC-AUC sebesar 0.9908. Nilai ini menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam membedakan pasien normal dan pasien terindikasi penyakit jantung pada data uji. Kurva ROC yang mendekati bagian kiri atas menunjukkan bahwa model memiliki tingkat sensitivitas yang tinggi dengan tingkat kesalahan yang rendah. Namun, nilai ROC-AUC yang sangat tinggi tetap perlu diinterpretasikan secara hati-hati karena dataset memiliki banyak data duplikat. Oleh karena itu, hasil evaluasi ini dapat digunakan sebagai bukti bahwa model bekerja dengan baik pada dataset yang digunakan, tetapi belum tentu langsung dapat digeneralisasi ke data medis nyata yang lebih kompleks.


H. Hasil Clustering K-Means

Selain klasifikasi, proyek ini juga menerapkan metode clustering menggunakan algoritma K-Means. Clustering digunakan untuk mengelompokkan pasien berdasarkan kemiripan karakteristik klinis. Berbeda dengan klasifikasi, clustering tidak menggunakan atribut target dalam proses pembentukan kelompok. Sebelum clustering dilakukan, data terlebih dahulu distandardisasi agar setiap fitur memiliki skala yang seimbang. Setelah itu, dilakukan pengujian jumlah cluster menggunakan silhouette score. Nilai silhouette score digunakan untuk melihat kualitas pengelompokan data. Semakin tinggi nilai silhouette score, semakin baik pemisahan antar cluster.



Gbr. 4.8 Silhouette Score K-Means

Hasil evaluasi K-Means menunjukkan bahwa jumlah cluster terbaik berdasarkan silhouette score adalah 2 cluster. Nilai silhouette score untuk 2 cluster adalah 0.1701. Nilai ini menunjukkan bahwa pemisahan cluster masih tergolong rendah, tetapi tetap dapat digunakan sebagai analisis tambahan untuk memahami pola kelompok pasien. Hasil silhouette score yang tidak terlalu tinggi dapat terjadi karena karakteristik pasien pada dataset saling berdekatan dan tidak membentuk kelompok yang benar-benar terpisah secara jelas. Hal ini umum terjadi pada data kesehatan karena kondisi pasien dapat memiliki variasi yang kompleks dan saling tumpang tindih.



Gbr. 4.9 Distribusi Data pada Setiap Cluster

Gambar 4.9 menunjukkan jumlah data pada setiap cluster. Distribusi ini digunakan untuk melihat apakah hasil clustering menghasilkan kelompok yang terlalu timpang atau masih dapat dianalisis. Jika salah satu cluster terlalu kecil, maka interpretasi cluster perlu dilakukan lebih hati-hati.

I. Karakteristik Cluster


Setelah data dikelompokkan menggunakan K-Means, dilakukan analisis karakteristik masing-masing cluster. Analisis ini dilakukan dengan melihat rata-rata beberapa atribut klinis pada setiap cluster, seperti usia, tekanan darah, kolesterol, detak jantung maksimum, oldpeak, dan target.

Cluster	Rata-rata Usia	Tekanan Darah	Kolesterol	Detak Jantung Maksimum
Cluster 0	52.21	129.43	242.20	160.19
Cluster 1	58.34	135.44	252.67	129.68

Tabel 4.2 Karakteristik Clustering

Berdasarkan tabel tersebut, Cluster 0 memiliki rata-rata usia lebih rendah, detak jantung maksimum lebih tinggi, dan nilai oldpeak lebih rendah. Rata-rata target pada Cluster 0 adalah 0.75, yang menunjukkan bahwa cluster ini memiliki proporsi pasien terindikasi penyakit jantung yang lebih tinggi dalam dataset.

Sementara itu, Cluster 1 memiliki rata-rata usia lebih tinggi, tekanan darah dan kolesterol yang lebih tinggi, tetapi rata-rata target hanya 0.10. Hal ini menunjukkan bahwa pola pada dataset tidak selalu mengikuti asumsi sederhana bahwa usia, tekanan darah, atau kolesterol yang lebih tinggi selalu langsung menghasilkan target penyakit jantung yang lebih tinggi. Oleh karena itu, analisis penyakit jantung perlu mempertimbangkan banyak atribut secara bersamaan.



Gbr. 4.10 Persentase Target Risiko Jantung per Cluster

Gambar 4.10 menunjukkan persentase target risiko penyakit jantung pada setiap cluster. Dari gambar tersebut, terlihat bahwa setiap cluster memiliki karakteristik risiko yang berbeda. Hasil ini menunjukkan bahwa clustering dapat membantu memberikan gambaran kelompok pasien berdasarkan pola data klinisnya.

J. Pembahasan Hasil Aplikasi Streamlit

Model dan hasil analisis kemudian diimplementasikan ke dalam aplikasi web berbasis Streamlit. Aplikasi yang dikembangkan memiliki beberapa halaman utama, yaitu Beranda, Dataset, Prediksi, XAI Analysis, Dashboard, dan Tentang. Aplikasi ini dibuat agar hasil analisis Data Mining dapat ditampilkan secara lebih interaktif dan mudah dipahami.

Pada halaman Beranda, pengguna dapat melihat informasi umum mengenai proyek, anggota kelompok, fitur utama aplikasi, dan tahapan CRISP-DM. Halaman ini berfungsi sebagai pengantar agar pengguna memahami tujuan aplikasi. Pada halaman Dataset, pengguna dapat melihat informasi dataset, seperti jumlah data, jumlah fitur, data lengkap, jumlah data duplikat, dan jumlah kelas target. Selain itu, pengguna juga dapat melihat data secara interaktif, statistik deskriptif, distribusi fitur, serta korelasi antar atribut.

Pada halaman Prediksi, pengguna dapat memasukkan data klinis pasien melalui form input. Data yang dimasukkan akan diproses oleh model untuk menghasilkan prediksi risiko penyakit jantung. Aplikasi menampilkan hasil prediksi dalam bentuk kategori risiko rendah atau risiko tinggi, disertai probabilitas model.

Pada halaman XAI Analysis, aplikasi menampilkan penjelasan model menggunakan SHAP dan LIME. Fitur ini berguna untuk membantu memahami faktor-faktor yang memengaruhi hasil prediksi. SHAP digunakan untuk melihat tingkat kepentingan fitur secara global, sedangkan LIME digunakan untuk menjelaskan prediksi pada satu data pasien tertentu. Pada halaman Dashboard, aplikasi menampilkan visualisasi performa model dan analisis data secara interaktif. Dashboard ini membantu pengguna memahami hasil analisis dengan lebih mudah melalui grafik dan tabel.

Secara keseluruhan, aplikasi Streamlit berhasil menjadi media implementasi hasil Data Mining. Dengan adanya aplikasi ini, proses analisis tidak hanya berhenti pada notebook, tetapi dapat digunakan dalam bentuk sistem sederhana yang interaktif.

K. Pembahasan Umum

Berdasarkan hasil analisis, penerapan Data Mining pada *Heart Disease Dataset* dapat membantu memahami pola data pasien dan membangun model prediksi risiko penyakit jantung. Metode klasifikasi digunakan untuk memprediksi status pasien, sedangkan metode clustering digunakan untuk mengelompokkan pasien berdasarkan kemiripan karakteristik klinis. Model klasifikasi menunjukkan performa yang cukup baik, terutama Random Forest dan Ensemble. Namun, hasil evaluasi yang sangat tinggi perlu dijelaskan secara hati-hati karena dataset memiliki banyak data duplikat. Data duplikat dapat membuat model lebih mudah mengenali data uji jika data yang sama atau sangat mirip sudah pernah muncul pada data latih.

Metode clustering menggunakan K-Means menghasilkan 2 cluster sebagai jumlah cluster terbaik berdasarkan silhouette score. Meskipun nilai silhouette score tidak terlalu tinggi, clustering tetap memberikan gambaran tambahan mengenai kelompok pasien dalam dataset. Hasil clustering menunjukkan bahwa kelompok pasien dapat memiliki karakteristik klinis yang berbeda. Aplikasi Streamlit yang dibuat juga memberikan nilai tambah karena hasil model dapat digunakan secara interaktif. Fitur prediksi membantu pengguna memasukkan data pasien dan melihat hasil prediksi. Fitur visualisasi membantu memahami dataset, sedangkan fitur XAI membantu menjelaskan faktor yang memengaruhi prediksi model.

Namun, aplikasi ini memiliki keterbatasan. Dataset yang digunakan merupakan dataset sekunder dari Kaggle dan tidak dapat menggantikan pemeriksaan medis langsung. Selain

itu, hasil prediksi model sangat bergantung pada data yang digunakan saat pelatihan. Oleh karena itu, aplikasi ini hanya digunakan untuk tujuan pembelajaran dan demonstrasi penerapan Data Mining, bukan sebagai alat diagnosis medis.

V. IMPLEMENTASI SISTEM


A. Arsitektur Aplikasi

Implementasi sistem pada proyek ini dilakukan dengan membangun aplikasi web berbasis Streamlit. Aplikasi ini dibuat agar hasil analisis Data Mining tidak hanya ditampilkan melalui notebook, tetapi juga dapat digunakan dalam bentuk aplikasi yang lebih interaktif dan mudah dipahami oleh pengguna. Aplikasi yang dikembangkan diberi nama HeartAI, yaitu sistem analisis dan prediksi risiko penyakit jantung berdasarkan data klinis pasien.

Secara umum, aplikasi HeartAI terdiri dari beberapa komponen utama, yaitu pengguna, aplikasi Streamlit, dataset, model machine learning, visualisasi data, dan output hasil analisis. Pengguna berinteraksi dengan aplikasi melalui tampilan web. Data yang dimasukkan oleh pengguna kemudian diproses oleh aplikasi menggunakan model yang telah dibuat. Setelah itu, aplikasi akan menampilkan hasil prediksi risiko penyakit jantung, probabilitas model, visualisasi data, dan informasi pendukung lainnya.

Dataset yang digunakan pada aplikasi adalah file heart.csv.csv yang disimpan dalam folder dataset. Dataset ini digunakan untuk menampilkan informasi data, statistik deskriptif, distribusi target, korelasi antar fitur, dan visualisasi lainnya. Model machine learning dibangun menggunakan beberapa algoritma, yaitu Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Ensemble. Selain itu, aplikasi juga dilengkapi dengan fitur Explainable AI menggunakan SHAP dan LIME untuk membantu menjelaskan faktor-faktor yang memengaruhi hasil prediksi.

Arsitektur aplikasi dibuat sederhana agar mudah dijalankan dan dipahami. Pengguna memasukkan data pasien melalui form input, kemudian aplikasi memproses data tersebut menggunakan model yang telah disiapkan. Hasil pemrosesan ditampilkan dalam bentuk prediksi risiko, grafik, tabel, serta penjelasan model.



Gbr. 5.1 Arsitektur Aplikasi HeartAI

Gambar 5.1 menunjukkan arsitektur sederhana aplikasi HeartAI. Pengguna memasukkan data klinis pasien melalui aplikasi Streamlit. Aplikasi membaca dataset dan menjalankan model machine learning. Setelah proses analisis dilakukan, aplikasi menampilkan hasil berupa kategori risiko, probabilitas, grafik, dashboard, dan informasi pendukung lainnya.

B. Struktur Halaman Aplikasi

Aplikasi HeartAI memiliki beberapa halaman utama yang dapat diakses melalui menu navigasi pada sidebar. Sidebar digunakan untuk memudahkan pengguna berpindah dari satu halaman ke halaman lainnya. Halaman-halaman tersebut dibuat sesuai dengan kebutuhan proyek Data Mining, mulai dari pengenalan proyek, eksplorasi dataset, prediksi, penjelasan model, dashboard, hingga informasi proyek.

Halaman yang terdapat dalam aplikasi adalah sebagai berikut:

1. Beranda, berisi judul aplikasi, deskripsi proyek, identitas anggota kelompok, fitur utama aplikasi, dan tahapan CRISP-DM.
2. Dataset, berisi informasi dataset, jumlah data, jumlah fitur, data duplikat, statistik deskriptif, distribusi target, distribusi fitur, dan korelasi antar atribut.
3. Prediksi, berisi form input data klinis pasien, tombol proses analisis, hasil prediksi risiko penyakit jantung, probabilitas model, profil klinis pasien, confusion matrix, dan kurva ROC.
4. XAI Analysis, berisi penjelasan hasil model menggunakan SHAP dan LIME untuk membantu memahami faktor yang memengaruhi prediksi.
5. Dashboard, berisi visualisasi performa model dan analitik data secara interaktif.


6. Tentang, berisi informasi proyek, teknologi yang digunakan, deskripsi fitur, serta disclaimer bahwa aplikasi bukan alat diagnosis medis.

Struktur halaman dibuat agar pengguna dapat memahami proses analisis secara bertahap. Pengguna dapat memulai dari halaman Beranda untuk memahami tujuan aplikasi, kemudian melihat dataset, mencoba prediksi, memahami penjelasan model, melihat dashboard, dan membaca informasi proyek pada halaman Tentang.

C. Implementasi Halaman Beranda

Halaman Beranda merupakan halaman awal yang ditampilkan ketika aplikasi dijalankan. Pada halaman ini ditampilkan judul aplikasi, deskripsi singkat proyek, identitas anggota kelompok, fitur utama aplikasi, dan tahapan metodologi CRISP-DM. Pada bagian awal halaman Beranda, aplikasi menampilkan informasi bahwa sistem ini merupakan proyek UAS mata kuliah Data Mining yang menerapkan metodologi CRISP-DM untuk analisis dan prediksi penyakit jantung. Informasi ini bertujuan untuk memberikan gambaran kepada pengguna mengenai tujuan utama pembuatan aplikasi.

Halaman Beranda juga menampilkan identitas anggota kelompok, yaitu nama dan NIM mahasiswa. Selain itu, terdapat bagian fitur utama aplikasi yang berisi tiga fitur penting, yaitu Model Ensemble, Explainable AI, dan Dashboard Interaktif. Model Ensemble digunakan untuk menggabungkan beberapa algoritma machine learning, Explainable AI digunakan untuk membantu menjelaskan hasil prediksi, sedangkan Dashboard Interaktif digunakan untuk menampilkan visualisasi data dan performa model.





Gambar 5.2 Tampilan halaman Beranda aplikasi HeartAI.

Pada halaman ini terlihat judul proyek, deskripsi aplikasi, identitas anggota kelompok, fitur utama aplikasi, dan tahapan CRISP-DM yang digunakan dalam proyek.

D. Implementasi Halaman Dataset


Halaman Dataset digunakan untuk menampilkan informasi mengenai dataset yang digunakan dalam proyek. Pada halaman ini, pengguna dapat melihat beberapa metrik utama, seperti total data, jumlah fitur, jumlah data lengkap, jumlah data duplikat, dan jumlah kelas target. Berdasarkan dataset yang digunakan, aplikasi menampilkan bahwa dataset memiliki 1.025 data, 13 fitur, 1.025 data lengkap, 723 data duplikat, dan 2 kelas target. Informasi ini penting karena pengguna dapat mengetahui kondisi dataset sebelum data digunakan dalam proses pemodelan.

Halaman Dataset juga menyediakan beberapa tab analisis, yaitu Eksplorasi Data, Statistik, Distribusi, dan Korelasi. Tab Eksplorasi Data digunakan untuk menampilkan data secara interaktif. Pengguna dapat melakukan filter berdasarkan target dan rentang usia. Tab Statistik digunakan untuk menampilkan statistik deskriptif dan distribusi target. Tab Distribusi digunakan untuk melihat penyebaran fitur tertentu berdasarkan target. Tab Korelasi digunakan untuk menampilkan matriks korelasi dan feature importance.




Gbr. 5.3 Tampilan Informasi Dataset

Gambar 5.3 menunjukkan informasi utama dataset pada aplikasi HeartAI. Informasi yang ditampilkan meliputi total data, jumlah fitur, data lengkap, data duplikat, dan kelas target.




Gbr. 5.4 Tampilan Eksplorasi Data Interaktif

Gambar 5.4 menunjukkan fitur eksplorasi data interaktif. Pada bagian ini, pengguna dapat memilih target tertentu dan mengatur rentang usia untuk melihat data yang sesuai dengan filter tersebut. Fitur ini membantu pengguna memahami isi dataset secara lebih fleksibel.




Gbr. 5.5 Tampilan Statistik dan Distribusi Target

Gambar 5.5 menunjukkan tampilan statistik deskriptif dan distribusi target. Statistik deskriptif digunakan untuk melihat nilai rata-rata, standar deviasi, nilai minimum, dan nilai maksimum dari setiap atribut. Distribusi target digunakan untuk melihat perbandingan jumlah pasien normal dan pasien terindikasi penyakit jantung.



Gbr. 5.6 Tampilan Distribusi Fitur

Gambar 5.6 menunjukkan distribusi salah satu fitur berdasarkan target. Pada contoh tersebut, fitur yang ditampilkan adalah usia. Visualisasi ini membantu pengguna melihat penyebaran nilai fitur pada masing-masing kelas target.



Gbr. 5.7 Tampilan Korelasi dan Feature Importance

Gambar 5.7 menunjukkan matriks korelasi dan feature importance. Matriks korelasi digunakan untuk melihat hubungan antar atribut, sedangkan feature importance digunakan untuk melihat fitur yang dianggap paling berpengaruh oleh model Random Forest dalam proses prediksi.

E. Implementasi Halaman Prediksi

Halaman Prediksi merupakan halaman utama yang digunakan untuk melakukan prediksi risiko penyakit jantung. Pada halaman ini, pengguna diminta mengisi data klinis pasien melalui form input yang telah disediakan. Form input dibuat dalam beberapa bagian agar lebih mudah digunakan, yaitu Demografi dan Tanda Vital, Indikator Jantung, serta Hasil Lab.

Data yang dimasukkan oleh pengguna meliputi usia, jenis kelamin, tipe nyeri dada, tekanan darah, kadar kolesterol, gula darah puasa, hasil EKG, detak jantung maksimum, angina akibat olahraga, nilai oldpeak, kemiringan segmen ST, jumlah pembuluh darah besar, dan thalassemia. Setelah data dimasukkan, pengguna dapat menekan tombol Jalankan Analisis untuk menjalankan proses prediksi.

Aplikasi kemudian mengubah data input pengguna menjadi bentuk tabel atau DataFrame sesuai urutan fitur yang digunakan model. Setelah itu, data input diproses menggunakan standardisasi agar memiliki skala yang sesuai dengan data pelatihan. Model kemudian melakukan prediksi dan menghitung probabilitas risiko penyakit jantung.

Hasil prediksi ditampilkan dalam bentuk kategori risiko, yaitu risiko rendah atau risiko tinggi. Selain itu, aplikasi juga menampilkan probabilitas model Ensemble agar pengguna dapat mengetahui tingkat keyakinan model terhadap hasil prediksi. Pada tampilan hasil, aplikasi juga menampilkan perbandingan prediksi dari beberapa model serta tingkat kesepakatan antar model.

Gbr. 5.8 Tampilan Form Input Prediksi

Gambar 5.8 menunjukkan form input pada halaman Prediksi. Pengguna dapat mengisi data klinis pasien melalui slider, radio button, dan select box yang telah disediakan. Tampilan form dibuat agar pengguna lebih mudah memasukkan nilai sesuai data pasien.



Gbr. 5.9 Tampilan Hasil Prediksi Risiko Penyakit Jantung


Gambar 5.9 menunjukkan hasil prediksi setelah pengguna menekan tombol Jalankan Analisis. Pada contoh tersebut, aplikasi menampilkan hasil risiko tinggi terdeteksi dengan probabilitas model Ensemble sebesar 73,4%. Aplikasi juga menampilkan perbandingan probabilitas risiko dari beberapa model dan tingkat kesepakatan model.

F. Implementasi Explainable AI

Aplikasi HeartAI dilengkapi dengan fitur Explainable AI pada halaman XAI Analysis. Fitur ini digunakan untuk membantu pengguna memahami alasan di balik hasil prediksi model. Hal ini penting karena model machine learning sering dianggap sulit dipahami jika hanya menampilkan hasil akhir berupa prediksi.

Metode Explainable AI yang digunakan dalam aplikasi adalah SHAP dan LIME. SHAP digunakan untuk melihat tingkat kepentingan fitur secara global. Dengan SHAP, pengguna dapat mengetahui fitur mana saja yang secara umum paling berpengaruh terhadap hasil prediksi model. Sementara itu, LIME digunakan untuk menjelaskan prediksi pada satu data pasien tertentu, sehingga pengguna dapat memahami fitur apa saja yang mendorong hasil prediksi ke arah risiko rendah atau risiko tinggi.

Pada tampilan XAI Analysis, aplikasi menampilkan grafik tingkat kepentingan fitur berdasarkan SHAP dan Random Forest. Grafik tersebut membantu pengguna memahami faktor-faktor yang paling berpengaruh dalam proses prediksi. Fitur seperti ca, thal, cp, oldpeak, dan thalach terlihat menjadi fitur yang cukup berpengaruh dalam model.



Gbr. 5.10 Tampilan Explainable AI Menggunakan SHAP

Gambar 5.10 menunjukkan tampilan halaman XAI Analysis pada aplikasi HeartAI. Pada halaman ini terdapat


grafik tingkat kepentingan fitur global menggunakan SHAP dan feature importance dari Random Forest. Visualisasi ini membantu menjelaskan fitur yang paling memengaruhi hasil prediksi model.

G. Implementasi Dashboard

Halaman Dashboard digunakan untuk menampilkan visualisasi analitik secara lebih ringkas dan interaktif. Pada halaman ini, aplikasi menampilkan performa model machine learning menggunakan grafik dan tabel. Model yang ditampilkan pada dashboard antara lain Regresi Logistik, Random Forest, dan Gradient Boosting.

Dashboard menampilkan performa cross-validation 5-fold, akurasi data test, dan tabel ringkasan performa model. Berdasarkan tampilan dashboard, Random Forest memiliki nilai rata-rata cross-validation tertinggi dibandingkan model lain yang ditampilkan. Informasi ini membantu pengguna membandingkan performa model secara lebih mudah.

Selain performa model, dashboard juga menampilkan analitik data secara real-time, seperti risiko berdasarkan kelompok usia dan hubungan antara kolesterol dengan detak jantung maksimum. Visualisasi ini membantu pengguna memahami pola data pasien secara lebih interaktif.



Gbr. 5.11 Tampilan Dashboard Performa Model

Gambar 5.11 menunjukkan halaman Dashboard yang berisi grafik performa model dan tabel evaluasi. Dashboard ini memudahkan pengguna membandingkan hasil model tanpa harus membuka notebook analisis.


H. Implementasi Halaman Tentang

Halaman Tentang berisi informasi mengenai proyek, anggota kelompok, teknologi yang digunakan, informasi dataset, deskripsi fitur, dan disclaimer penggunaan aplikasi.

Halaman ini berfungsi sebagai bagian penjelasan tambahan agar pengguna memahami tujuan aplikasi dan batasan penggunaannya.

Pada halaman Tentang, aplikasi menampilkan bahwa proyek ini merupakan proyek UAS Data Mining yang menerapkan metodologi CRISP-DM untuk analisis dan prediksi penyakit jantung. Halaman ini juga menampilkan anggota kelompok beserta NIM. Selain itu, terdapat informasi mengenai model machine learning yang digunakan, seperti Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble. Terdapat juga penjelasan mengenai teknologi Explainable AI, yaitu SHAP dan LIME.

Bagian penting pada halaman ini adalah disclaimer. Disclaimer menjelaskan bahwa aplikasi dikembangkan untuk tujuan edukasi dan pembelajaran, sehingga hasil prediksi tidak dapat digunakan sebagai diagnosis medis. Pengguna tetap harus berkonsultasi dengan dokter atau tenaga medis profesional untuk pemeriksaan kesehatan yang sebenarnya.



Gbr. 5.12 Tampilan Halaman Tentang Proyek

Gambar 5.12 menunjukkan halaman Tentang pada aplikasi HeartAI. Halaman ini berisi informasi proyek, anggota kelompok, teknologi yang digunakan, informasi dataset, dan deskripsi fitur.

I. Pengujian Aplikasi

Pengujian aplikasi dilakukan untuk memastikan bahwa setiap halaman dan fitur dapat berjalan sesuai dengan fungsinya. Pengujian dilakukan dengan menjalankan aplikasi menggunakan perintah streamlit run app.py, kemudian membuka aplikasi melalui browser. Pengujian dilakukan pada halaman Beranda, Dataset, Prediksi, XAI Analysis, Dashboard, dan Tentang. Pada halaman Beranda, dilakukan pengecekan apakah judul, deskripsi proyek, fitur utama, dan identitas anggota tampil dengan benar. Pada halaman Dataset,

dilakukan pengecekan apakah dataset berhasil dimuat, metrik dataset tampil, dan grafik dapat ditampilkan.

Pada halaman Prediksi, dilakukan pengecekan terhadap form input pasien, tombol Jalankan Analisis, hasil prediksi, grafik perbandingan model, dan tingkat kesepakatan model. Pada halaman XAI Analysis, dilakukan pengecekan apakah grafik SHAP dan feature importance dapat muncul. Pada halaman Dashboard, dilakukan pengecekan apakah grafik performa model dan tabel evaluasi dapat ditampilkan. Pada halaman Tentang, dilakukan pengecekan apakah informasi proyek dan deskripsi fitur tampil dengan benar.

Hasil pengujian menunjukkan bahwa aplikasi dapat berjalan dan setiap halaman dapat menampilkan informasi sesuai fungsinya. Form input dapat digunakan untuk memasukkan data pasien, tombol analisis dapat menjalankan proses prediksi, dan hasil prediksi dapat ditampilkan kepada pengguna.

J. Hasil Implementasi Sistem

Berdasarkan implementasi yang dilakukan, aplikasi HeartAI berhasil menampilkan informasi dataset, visualisasi data, prediksi risiko penyakit jantung, penjelasan model, dashboard analitik, dan informasi proyek. Aplikasi ini dapat membantu pengguna memahami hasil analisis Data Mining dengan lebih mudah karena seluruh proses disajikan dalam bentuk web interaktif.

Aplikasi juga dapat menerima input data klinis pasien dan memberikan hasil prediksi berupa kategori risiko rendah atau risiko tinggi. Selain itu, aplikasi menampilkan probabilitas model sehingga pengguna dapat mengetahui tingkat keyakinan prediksi. Fitur visualisasi membantu pengguna memahami pola pada dataset, sedangkan fitur Explainable AI membantu menjelaskan faktor yang memengaruhi hasil prediksi model.

Dengan adanya implementasi sistem ini, proyek Data Mining tidak hanya menghasilkan model di dalam notebook, tetapi juga menghasilkan aplikasi sederhana yang dapat digunakan sebagai media pembelajaran. Namun, aplikasi ini tetap memiliki keterbatasan. Hasil prediksi yang diberikan hanya digunakan untuk tujuan edukasi dan tidak dapat menggantikan diagnosis dokter atau tenaga medis profesional.

VI. KESIMPULAN

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa penerapan Data Mining pada *Heart Disease Dataset* dapat membantu menganalisis pola data klinis pasien dan memberikan prediksi awal risiko penyakit jantung. Proyek ini menggunakan metode *classification* dengan algoritma Regresi Logistik, Random Forest, Gradient Boosting, SVM, dan Voting Ensemble untuk memprediksi apakah pasien termasuk kategori normal atau berisiko penyakit jantung, serta metode *clustering* menggunakan K-Means untuk mengelompokkan pasien berdasarkan kemiripan karakteristik kesehatannya. Hasil evaluasi menunjukkan bahwa model Random Forest dan Voting Ensemble memiliki performa yang baik dalam melakukan prediksi, sedangkan K-Means dapat digunakan sebagai analisis tambahan untuk memahami pola kelompok pasien. Hasil model dan analisis kemudian diimplementasikan ke dalam aplikasi web berbasis Streamlit bernama **HeartAI**, yang memiliki fitur Beranda, Dataset, Prediksi, XAI Analysis, Dashboard, dan Tentang. Aplikasi ini dapat menampilkan informasi dataset, visualisasi data, hasil prediksi, probabilitas model, penjelasan fitur yang memengaruhi prediksi menggunakan SHAP dan LIME, serta dashboard performa model. Dengan demikian, HeartAI dapat menjadi media pembelajaran yang membantu pengguna memahami penerapan Data Mining dalam bidang kesehatan. Namun, hasil prediksi dari aplikasi ini hanya digunakan untuk tujuan edukasi dan tidak dapat menggantikan diagnosis dokter atau tenaga medis profesional.

REFERENSI

- [1] World Health Organization, "Cardiovascular diseases (CVDs)," *World Health Organization*, 2025. [Online]. Available: [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)). [Accessed: Jun. 2026].
- [2] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Waltham, MA, USA: Morgan Kaufmann, 2012.
- [3] Kaggle, "Heart Disease Dataset," *Kaggle Dataset*, 2024. [Online]. Available: <https://www.kaggle.com/datasets/moazeldsokyx/heart-disease>. [Accessed: Jun. 2026].
- [4] J. MacQueen, "Some Methods for Classification and Analysis of Multivariate Observations," in *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, Berkeley, CA, USA, 1967, vol. 1, pp. 281–297.
- [5] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, and R. Wirth, "CRISP-DM 1.0: Step-by-step Data Mining Guide," SPSS, 2000.
- [6] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Waltham, MA, USA: Morgan Kaufmann, 2012.

- [7] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, and R. Wirth, "CRISP-DM 1.0: Step-by-step Data Mining Guide," SPSS, 2000.
- [8] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.
- [9] NYC Taxi and Limousine Commission. (2025). TLC Trip Record Data - Yellow Taxi Trip Records. [Online]. Available: <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page> (Tanggal akses: 2 Juni 2026).
- [10] WJ. MacQueen, "Some Methods for Classification and Analysis of Multivariate Observations," in *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, Berkeley, CA, USA, 1967, vol. 1, pp. 281–297.
- [11] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [12] Streamlit Inc., "Streamlit Documentation," Streamlit, 2025. [Online]. Available: <https://docs.streamlit.io>. [Accessed: Jun. 2026].
- [13] R. Detrano et al., "International Application of a New Probability Algorithm for the Diagnosis of Coronary Artery Disease," *The American Journal of Cardiology*, vol. 64, no. 5, pp. 304–310, 198.
- [14] S. Mohan, C. Thirumalai, and G. Srivastava, "Effective Heart Disease Prediction Using Hybrid Machine Learning Techniques," *IEEE Access*, vol. 7, pp. 81542–81554, 2019, doi: 10.1109/ACCESS.2019.2923707.
- [15] K. Uyar and A. İlhan, "Diagnosis of Heart Disease Using Genetic Algorithm Based Trained Recurrent Fuzzy Neural Networks," *Procedia Computer Science*, vol. 120, pp. 588–593, 2017.

LAMPIRAN

Dataset :  UAS_BigData
 Aplikasi :
 Vidio Presentasi dan Demo Aplikasi :
 Source Code :  Salinan lain dari UAS_BigData.ipynb
 Repository Project :

Buatlah kelompok dengan anggota **maksimal 2 orang**. Gunakan template ini untuk membuat laporan ([download here](#)), yang diunggah hanya file laporan format artikel dengan link terkait dengan:

1. Dataset
2. Aplikasi
3. Video Presentasi dan Demo APlikasi
4. Source Code Jupyter Notebbok dan Apps
5. Repository Project